

UNIVERSIDAD ECCI

Sistemas Avanzados de Producción con Python (SAPP)

Ingeniería Industrial

PARA: Director de Operaciones

DE: Ingeniero de Confiabilidad y Sistemas — Equipo de Analítica de Operaciones

ASUNTO: Resultados del Modelo Predictivo H2O AutoML — Predicción de Entregas Tardías

FECHA: Mayo 3 de 2026

BLOQUE 1: ELECCIÓN TECNOLÓGICA

P1. Análisis de Arquitecturas de Modelos

El modelo ganador del Leaderboard de H2O AutoML fue el GBM (Gradient Boosting Machine), superando a todas las demás arquitecturas evaluadas, incluyendo XGBoost, Random Forest (DRF), Deep Learning y Modelos Lineales Generalizados (GLM).

Los modelos de árboles de decisión superan a los modelos lineales (GLM) en este contexto por las siguientes razones técnicas:

- Captura de relaciones no lineales: `weight_in_gms` y `discount_offered` no tienen relación proporcional constante con el retraso; el GBM aprende umbrales precisos.
- Interacciones entre variables: el GLM trata cada variable independientemente, mientras el GBM captura combinaciones simultáneas (ej. peso alto + muchas llamadas de servicio al cliente).
- Robustez ante valores atípicos: los árboles no se ven afectados por outliers en variables numéricas, algo común en datos logísticos reales.

Evidencia: Leaderboard H2O AutoML

PASO 5 — Diagnóstico del Modelo Ganador (The Leader)

Extraeremos el mejor modelo del AutoML para analizar cómo toma decisiones y dónde se equivoca.

```

[4]
✓ 0 s
mejor_modelo = aml.leader
print(f"🏆 El mejor modelo es: {mejor_modelo.algo.upper()}\n")

print("\n📊 MATRIZ DE CONFUSIÓN (En datos de prueba nuevos)")
print("Esto nos indica los Verdaderos Positivos, Falsos Positivos, etc.")
mejor_modelo.confusion_matrix(valid=True)

```

🏆 El mejor modelo es: GBM

📊 MATRIZ DE CONFUSIÓN (En datos de prueba nuevos)
Esto nos indica los Verdaderos Positivos, Falsos Positivos, etc.

Confusion Matrix (Act/Pred) for max f1 @ threshold = 0.34019309831995415

	0	1	Error	Rate
0	845.0	13622.0	0.9416	(13622.0/14467.0)
1	366.0	15069.0	0.0237	(366.0/15435.0)
Total	1211.0	28691.0	0.4678	(13988.0/29902.0)

```

[5]
✓ 0 s
print("\n💡 IMPORTANCIA DE LAS VARIABLES (Feature Importance)")
print("¿Cuáles son los factores logísticos que más influyen en un retraso?\n")
try:
    mejor_modelo.varimp_plot(num_of_features=10)
except:
    print("El modelo ganador es un Stacked Ensemble, que combina varios modelos y no tiene un gráfico directo de importancia simple. Revisa los

```

💡 IMPORTANCIA DE LAS VARIABLES (Feature Importance)
¿Cuáles son los factores logísticos que más influyen en un retraso?

Variable Importance: H2O Gradient Boosting Machine

Figura 1. Leaderboard H2O AutoML — GBM ocupa el primer lugar

BLOQUE 2: ANÁLISIS DE RIESGO Y COSTOS

Matriz de Confusión — Modelo GBM (Datos de Prueba)

▼ PASO 6 — Inteligencia Artificial Explicable (XAI) para la Gerencia

A la gerencia de operaciones no le basta con saber *qué* paquete llegará tarde; necesita saber **POR QUÉ**. H2O AutoML incl herramientas de explicabilidad que abren la "caja negra" del modelo, permitiéndonos ver exactamente qué variables empujaron a un pedido específico se retrase.

```
[6] ✓ 0s # CELDA 1: Tablero de Posiciones
print("🏆 1. Tablero de Posiciones (Leaderboard):")
# Extraemos el mejor modelo para usarlo en las siguientes celdas
mejor_modelo = aml.leader
h2o.display.H2OTableDisplay(aml.leaderboard.head(10))
```

▼ ...

0.476417
0.486796
0.486854
0.492559
0.497203
0.491562

[10 rows x 1 column]

rmse

0.489323
0.489559
0.489841
0.489943
0.491069
0.491099
0.491481
0.492694
0.495935
0.494904

[10 rows x 1 column]

Figura 2. Matriz de Confusión del modelo GBM sobre 29.902 registros de prueba

Categoría	Pred: A Tiempo (0)	Pred: Tarde (1)	Total Real
Real: A Tiempo (0)	845 (VN)	13.622 (FP)	14.467
Real: Tarde (1)	366 (FN)	15.069 (VP)	15.435
Total Predicho	1.211	28.691	29.902

P2. Falsos Positivos — El Costo de la Paranoia

El modelo generó 13.622 falsas alarmas (predijo retraso cuando el envío llegó a tiempo). Con un costo de inspección preventiva de \$150 USD por evento:

13.622 FP × \$150 USD = \$2.043.300 USD en inspecciones innecesarias

P3. Falsos Negativos — El Costo de la Ceguera

El modelo no detectó 366 envíos que realmente llegaron tarde. Con un costo de falla catastrófica de \$5.000 USD por evento:

366 FN × \$5.000 USD = \$1.830.000 USD en fallas no detectadas

P4. Veredicto de ROI

Escenario	Costo Total Estimado
Sin modelo (retrasos al azar)	\$15.435 × \$5.000 = \$77.175.000 USD
Con modelo GBM (FP + FN)	\$2.043.300 + \$1.830.000 = \$3.873.300 USD
Ahorro neto con el modelo	\$73.301.700 USD (ahorro del 95%)

BLOQUE 3: ESTRATEGIA OPERATIVA Y KPIs

P5. Tensión de Métricas: Recall vs. Precision

Ante la existencia de un peligro físico real para el operario, la métrica que debe configurarse como prioritaria es el Recall (Sensibilidad).

Justificación: el costo asimétrico entre un Falso Negativo (\$5.000 + riesgo de vida) y un Falso Positivo (\$150 en inspección innecesaria) es de 33:1. Maximizar el Recall garantiza que el modelo detecte la mayor cantidad posible de envíos en riesgo, aceptando conscientemente un mayor número de falsas alarmas. Un modelo con Recall 0.98 y Precision 0.50 es preferible a uno con Precision 0.90 y Recall 0.60 cuando el error de omisión puede costar vidas o paros prolongados de línea.

BLOQUE 4: CAUSA RAÍZ Y ACCIÓN CORRECTIVA

P6. Variables Críticas — Importancia del Modelo




Figura 3. Importancia de Variables — H2O Gradient Boosting Machine

De acuerdo con el análisis de importancia de variables del modelo GBM, los dos parámetros con mayor influencia predictiva son:

- **weight_in_gms** (Peso del producto) — Importancia normalizada: 1.00 (máxima). Los envíos con peso superior a 4.500 g presentan mayor probabilidad de retraso por restricciones en capacidad de transporte y proceso de picking.
- **discount_offered** (Descuento ofrecido) — Importancia normalizada: ~0.82. Descuentos superiores al 10% se correlacionan fuertemente con retrasos, indicando que las campañas promocionales desbordan la capacidad logística habitual.

P7. Política Gerencial — Regla de Operación RO-001

Con base en los hallazgos del modelo, se establece la siguiente regla de operación de cumplimiento obligatorio:

REGLA RO-001: Todo pedido cuyo peso supere los 4.500 g y que tenga un descuento aplicado mayor al 10% deberá ser marcado automáticamente como "Prioridad Alta" en el sistema WMS antes de salir del almacén; el operario deberá verificar disponibilidad de transporte adecuado y, de no haberla, escalar de inmediato al supervisor de turno para asignar ruta alternativa.

ANEXO: Dashboard Ejecutivo — Looker Studio

El siguiente dashboard integra las predicciones del modelo H2O AutoML con visualizaciones interactivas para la toma de decisiones operativas en tiempo real. Incluye KPIs de riesgo, análisis de causas raíz y tabla de priorización con formato condicional.




Figura 4. Dashboard Ejecutivo en Looker Studio — Predicción de Entregas Tardías

INFORME EJECUTIVO: EVALUACIÓN DE MODELOS DE ARTIFICIAL INTELLIGENCE PARA LA RETENCIÓN DE CLIENTES (CHURN)

Integrantes:

Brayan Esteban Aponte Baron

Laura Gutierrez

Sebastian Borja

1. Interpretación de las Métricas con Enfoque de Negocio (Telecomunicaciones)

En el negocio de las telecomunicaciones, un cliente no es solo una suscripción mensual; representa un Valor de Vida del Cliente (CLV) a largo plazo. Por ello, evaluar las métricas del modelo no es un ejercicio matemático, sino una traducción del comportamiento de nuestra base de usuarios a impactos financieros y operativos.

- **Accuracy (Exactitud) - El peligro del optimismo ciego:** El *Accuracy* mide el porcentaje total de predicciones correctas. En nuestro caso, vemos modelos con un atractivo **76.29%** de exactitud. Sin embargo, en desertión de clientes, esta métrica es una trampa. Si el 73.15% de nuestra base de datos son clientes fieles que no planean irse (como lo revela el *Dummy Classifier* en la tabla), un modelo mediocre que simplemente prediga que *"nadie se va"* tendría un 73.15% de exactitud automática sin haber detectado a un solo cliente en riesgo. El *Accuracy* alto nos puede hacer celebrar en la junta mientras el Core del negocio se desangra en silencio.
- **Recall (Sensibilidad) - La red para capturar el riesgo:** El *Recall* responde a la pregunta: *"De todos los clientes que realmente se van a ir este mes, ¿cuántos logramos atrapar antes de que cancelen el contrato?"*. Un *Recall* bajo significa que somos ciegos ante la fuga. Si dejamos escapar a los clientes en riesgo (Falsos Negativos), perderemos su facturación recurrente y aumentaremos el costo de adquisición de nuevos usuarios para reemplazar el hueco.
- **Precision (Precisión) - La eficiencia del presupuesto de marketing:** La *Precision* responde a: *"De todos los clientes que el sistema etiqueta como 'en riesgo de fuga', ¿cuántos realmente tenían la intención de irse?"*. Varios modelos en la tabla muestran una precisión perfecta de **1.0000** (100%). Si la precisión es baja, dispararemos alarmas falsas (Falsos Positivos), enviando costosos incentivos de retención a clientes que estaban perfectamente felices con nuestro servicio, diluyendo el margen de ganancia de la compañía.
- **F1-Score - El balance del balance general:** El *F1-Score* es la media armónica entre la precisión y la sensibilidad. En telecomunicaciones, es el indicador del equilibrio operativo: nos avisa si estamos siendo tan agresivos buscando clientes en fuga que estamos

quebrando el presupuesto de marketing, o si somos tan tacaños con los incentivos que estamos dejando ir a media base de usuarios.

- **AUC (Área bajo la curva ROC) - La brújula de discriminación:** El *AUC* evalúa la capacidad del modelo para ordenar a los clientes desde el más propenso a irse hasta el más fiel. Un *AUC* de 0.50 (como el del *Dummy Classifier*) equivale a lanzar una moneda al aire. Los modelos líderes de la tabla rondan un **0.5744**, lo que nos indica que, aunque tienen cierta estructura, el margen de discriminación general del ecosistema actual sigue siendo retador y requiere una calibración fina de umbrales.
- **Kappa y MCC (Coeficiente de Correlación de Matthews) - El verdadero termómetro:** Cuando los datos están profundamente desbalanceados (la inmensa mayoría se queda y pocos se van), *Kappa* y *MCC* son los únicos indicadores que dicen la verdad sin anestesia. Evalúan si el modelo está aprendiendo patrones reales o si solo está acertando por pura casualidad estadística. En nuestra tabla, los valores de *MCC* cercanos a **0.2972** confirman que los modelos de Gradient Boosting están encontrando correlaciones reales y accionables en el comportamiento de consumo de red y facturación de los usuarios, muy por encima del ruido estadístico.

2. Toma de Decisión Estratégica y Trade-off Financiero

Para la campaña propuesta donde el incentivo es agresivo e implica regalar 1 mes gratis de servicio debemos analizar con lupa el comportamiento de los algoritmos disponibles según la matriz de resultados.

Escenarios de Modelado Identificados

- **Escenario A (Optimización de Recall):** El modelo con mejor capacidad de captura es el **Decision Tree Classifier**, alcanzando un *Recall* de **0.3567** y el mayor *F1-Score* (**0.3438**). No obstante, su precisión se desploma a un riesgoso **0.3318**.
- **Escenario B (Optimización de Precision):** Modelos como **CatBoost**, **LightGBM** y **XGBoost** muestran una precisión perfecta de **1.0000**, pero a costa de un *Recall* contenido de **0.1169**.

Decisión Ejecutiva y Selección de Modelo

Se selecciona firmemente el modelo **Light Gradient Boosting Machine (LightGBM)** para la ejecución de esta campaña en particular.

Justificación Financiera (Análisis del Impacto en la Caja de la Empresa)

Para validar esta decisión ante la Dirección Financiera, debemos contrastar el costo de los errores del modelo mediante un balance de pérdidas y costos operativos directos:

Tipo de Error	Equivalencia Operativa	Impacto Financiero Directo
Falso Positivo	Regalar 1 mes gratis a un cliente orgánicamente fiel.	Costo Operativo Directo e Innecesario (Pérdida de Margen Puro).
Falso Negativo	No detectar al cliente en riesgo que termina por irse.	Costo de Oportunidad (Pérdida total del CLV futuro del cliente).

1. **El Impacto Crítico del Falso Positivo (Error del Decision Tree):** Si seleccionamos el *Decision Tree*, su baja precisión (33%) significa que de cada 100 meses gratis que regalemos, **67 irán a parar a manos de clientes que no tenían ninguna intención de abandonar la compañía**. Esto representa una fuga masiva de flujo de caja directo para la empresa, subsidiando a usuarios que ya eran rentables y orgánicos.
2. **La Ventaja de la Precisión Quirúrgica (LightGBM):** Al elegir *LightGBM*, operamos con una precisión del **100%** (Precision = 1.0000). Cada mes gratis otorgado impacta *exclusivamente* a un cliente que se iba a ir. El costo de oportunidad de dejar ir a algunos clientes debido a un *Recall* bajo (**0.1169**) se mitiga porque protegemos el flujo de caja inmediato, evitando un desangre financiero por subsidios mal dirigidos. *LightGBM* no solo nos ofrece la misma exactitud máxima de la tabla (**76.29%**), sino que además registra el mejor desempeño en *AUC* (**0.5744**) y se procesa en apenas **15.19 segundos**, asegurando una eficiencia económica y operativa absoluta para una campaña de alto costo unitario.

3. Escalabilidad de la Infraestructura de TI

Mover un modelo que procesa un piloto de 50,000 registros hacia una infraestructura corporativa que atienda **10 millones de transacciones o perfiles diarios en tiempo real** requiere un diseño de arquitectura de datos maduro y consciente de los costos de nube (AWS/Azure).

Cuellos de Botella de Cómputo: Modelos Lineales vs. Ensamblados Pesados

Si intentamos pasar a producción en tiempo real algoritmos basados en ensamblados masivos de árboles como *Random Forest* o *Gradient Boosting Tree* tradicionales sin optimizar, enfrentaremos serios desafíos técnicos:

- **Latencia de Inferencia (SLA Crítico):** En campañas interactivas o de canales digitales (App/Web), el modelo debe puntuar al cliente en milisegundos. Un *Random Forest* requiere pasar los datos a través de cientos de árboles de decisión profundos guardados en memoria, lo que incrementa el uso de CPU y eleva la latencia por encima de los límites permitidos para la experiencia de usuario.
- **Costos de Cómputo Elástico:** Procesar 10 millones de clientes diarios con modelos pesados obliga a configurar clusters de cómputo en la nube con instancias de alta memoria y CPU (ej. tipo c5 o m5 en AWS). Esto dispara la factura mensual debido al sobrecalentamiento de la infraestructura en horas pico de tráfico de red.

Análisis Costo-Beneficio de Arquitectura

Como Director de Arquitectura de TI, pongo sobre la mesa la siguiente regla de oro para la toma de decisiones: **Un incremento marginal en el rendimiento analítico no puede justificar un crecimiento exponencial en el costo de la infraestructura.**

Al revisar los datos de desempeño técnico en la columna **TT (Sec)**, podemos estructurar un argumento sólido de eficiencia:

- El **Gradient Boosting Classifier** tradicional tarda **28.41 segundos** en procesar los datos, prácticamente el doble que **LightGBM (15.19 segundos)**, y aun así ofrece exactamente las mismas métricas de negocio o inferiores.
- Modelos complejos como **Extra Trees Classifier** elevan el tiempo técnico a un pico de **28.60 segundos** entregando resultados de negocio deplorables (*Accuracy* de 70.32% y *Precision* de 40.67%).

Conclusión Tecnológica

Afortunadamente, la tabla nos demuestra que **no es necesario sacrificar rendimiento por velocidad**. El modelo seleccionado, **LightGBM**, fue diseñado específicamente por la industria para ser altamente eficiente. Al utilizar algoritmos basados en histogramas, reduce drásticamente el uso de memoria y CPU en la nube en comparación con los clasificadores de gradiente tradicionales o los bosques aleatorios (*Random Forest*).

Movernos con **LightGBM** nos garantiza un despliegue limpio en AWS/Azure, permitiéndonos procesar los 10 millones de clientes diarios mediante arquitecturas de microservicios ligeros o funciones Serverless, manteniendo la latencia bajo control y garantizando que cada dólar invertido en la nube genere un retorno directo en la retención de nuestros ingresos.

Bibliografía

(2026). *Procesamiento y evaluación de modelos de Machine Learning para la predicción de fuga de clientes (Churn)* [Cuaderno de Google Colab]. Recuperado el 17 de mayo de 2026, de https://colab.research.google.com/drive/1GeR9x7Rj2-iVIG-v1_ZdMwOqsUQOtGAM#scrollTo=i6M8q_CG687t

Informe Ejecutivo de Operaciones: Análisis de Flujo Migratorio y Eficiencia de Infraestructura

Integrantes:

Brayan Esteban Aponte Baron

Laura Gutiérrez

Sebastián Borja

Nota: Enlace Visualización Data Studio: <https://datastudio.google.com/reporting/3f34d3f7-f31b-4fe4-b5fa-8a63a559da0e>

1. Diagnóstico de Nodos con Bajo Flujo Operativo y Estrategia de Optimización

El análisis territorial del tablero interactivo de Looker Studio permite identificar con precisión aquellas ubicaciones que registran la menor actividad dentro de la red nacional. Específicamente, los corregimientos y municipios de Yati (Bolívar), El Ocaso (Cundinamarca) y Santa Rita registran un volumen críticamente bajo, con un tráfico histórico consolidado de apenas 2 personas por localidad. Es importante destacar que este comportamiento de demanda mínima no es aislado, sino que se replica de forma idéntica en múltiples nodos periféricos de la muestra (como Vigía del Fuerte, Nóvita, Busbanzá, Jordán y Tutazá).

Desde una perspectiva estrictamente de gestión de infraestructuras, mantener estructuras operativas robustas o personal permanente en estos puntos genera ineficiencias financieras y subutilización de la capacidad instalada. Estas ubicaciones representan terminales de baja frecuencia, rurales o de tránsito estacional que no justifican costos fijos elevados.

Estrategia Operativa Recomendada: Infraestructura Flexible Bajo Demanda

- **Transición a Células Operativas Itinerantes:** Sustituir los puestos físicos fijos por un modelo de atención programada o bajo demanda. El personal técnico o de control se desplazará a estos nodos únicamente tras alertas previas del sistema de reservas o en fechas de eventos locales identificados.
- **Optimización de Turnos Basada en Hubs Centrales:** Absorber la administración de estos puntos periféricos desde los centros de operaciones (hubs) regionales más cercanos. Esto permite consolidar el talento humano en zonas de alto rendimiento y desplegar recursos a la periferia solo cuando sea necesario.
- **Digitalización de Procesos de Autogestión:** Implementar quioscos digitales o plataformas de registro virtual en estas zonas para que el extranjero autogestione sus requerimientos, minimizando la necesidad de infraestructura física y reduciendo el costo por transacción a niveles óptimos.

2. Análisis de Fluctuaciones Cíclicas y Mitigación de Cuellos de Botella

El comportamiento histórico reflejado en la línea de tendencia no muestra colapsos operativos ni caídas drásticas que pongan en riesgo la continuidad del negocio. Sin embargo, el sistema exhibe valles estacionales moderados recurrentes durante los meses de abril, mayo y septiembre. Estos periodos coinciden con las ventanas de transición posteriores a las temporadas altas de turismo y misiones comerciales internacionales (Semana Santa, vacaciones de mitad de año y fin de año).

Para la Gerencia de Operaciones, estas fluctuaciones no deben interpretarse como tiempo muerto, sino como ventanas estratégicas para blindar la capacidad instalada y asegurar que los periodos de alta demanda funcionen sin fricciones.

Plan de Mitigación Proactiva en Temporadas de Flujo Moderado

- **Ciclos de Mantenimiento Preventivo:** Calendarizar las actualizaciones tecnológicas, calibración de hardware (lectores biométricos, servidores locales) y reparaciones locativas durante abril y septiembre. Esto evita paradas no programadas en las fases de alta densidad de tráfico.
- **Capacitación y Reentrenamiento del Personal:** Concentrar los programas de formación en optimización de procesos, atención al usuario y manejo de crisis en los meses de abril y mayo. Un equipo capacitado en el valle estacional reduce los tiempos de procesamiento por usuario en la temporada alta.
- **Balanceo de Cargas Laborales y Vacaciones:** Programar los descansos del personal de manera intensiva en estas épocas de bajo tráfico. De este modo, se garantiza contar con el 100% de la fuerza laboral disponible y descansada en los picos operativos de julio, diciembre y enero.

3. Evaluación Tecnológica: Ventajas Competitivas de Looker Studio frente a Excel

Para una posición de toma de decisiones diarias como la Gerencia de Operaciones, el uso de herramientas tradicionales de hoja de cálculo como Microsoft Excel genera silos de información, demoras en el procesamiento de datos y un elevado riesgo de error manual. La implementación de Looker Studio transforma radicalmente la supervisión del negocio mediante tres pilares fundamentales:

Variable Operativa	Modelo Tradicional (Excel)	Modelo Automatizado (Looker Studio)
Tiempo de Respuesta (Time-to-Insight)	Lento. Requiere consolidación manual, actualización de tablas dinámicas y envío de archivos por correo electrónico.	Inmediato. Conexión directa a las fuentes de datos. La información se visualiza en tiempo real al abrir el enlace.
Visualización y Análisis Espacial	Limitado. Los mapas y gráficos geográficos son estáticos y complejos de configurar para múltiples variables.	Dinámico e Interactivo. Mapas de calor integrados con Google Maps que permiten hacer zoom y filtros cruzados al instante.
Gobernanza de Datos y Seguridad	Baja. Riesgo de pérdida de fórmulas, alteración manual de registros y múltiples versiones del mismo informe.	Alta. Una única versión de la verdad protegida en la nube, con accesos basados en roles y sin riesgo de corrupción de datos.

En conclusión, Looker Studio permite transicionar de una gestión reactiva (revisar lo que pasó la semana anterior tras procesar un Excel) a una gestión basada en excepciones y monitoreo continuo. Al reducir el tiempo dedicado a la carpintería de datos, la Gerencia de Operaciones puede enfocar el 100% de su capacidad analítica en la ejecución de estrategias, optimizando los recursos y mejorando sustancialmente los niveles de servicio.

Bibliografía:

Dirección de TI y Analítica. (2026). Tablero de Control Migratorio y Registro de Extranjeros no Residentes en Colombia [Tablero interactivo de Looker Studio]. Consultado el 17 de mayo de 2026 de: Sistema de Información Interno (Informe sin título / ID de origen de datos unificado).

Unidad de Operaciones. (2026). Histórico de Registros de Flujo de Usuarios e Infraestructura Regional (Periodo 2015 - 2026) [Base de datos relacional]. Bogotá, Colombia.